Projet Big Data - Patrimoine arbore de Saint-Quentin

Fonctionnalites 1 & 2 : exploration, nettoyage, visualisation

21/04/2026

1 Presentation du jeu de donnees

Le jeu de donnees recense les arbres de la ville de Saint-Quentin (Aisne). Il contient **11421 lignes** et **37 colonnes**. On peut regrouper les variables en quatre familles :

- geographiques : `X`, `Y` (coordonnees Lambert-93), `clc_quartier`, `clc_secteur` ;
- descriptives de l'arbre : `nomfrancais`, `nomlatin`, `feuillage`, `remarquable`, `fk_stadedev`, `fk_port`, `fk_pied`, `fk_situation`, `fk_revetement` ;
- metriques : `haut_tot`, `haut_tronc`, `tronc_diam`, `age_estim` ;
- etat/historique : `fk_arb_etat`, `dte_plantation`, `dte_abattage`, `clc_nbr_diag`.

Le reste (`OBJECTID`, `GlobalID`, `created_*`, `last_edited_*`, `Creator`...) est de la metadonnee de saisie, peu utile pour l'analyse.

2 Statistiques descriptives

2.1 Univariees

2.1.1 Variables numeriques

Table 1: Resume des variables numeriques (apres nettoyage).

var	min	med	moy	max	NA
haut_tot	1.0	8.0	10.4	37	NA
haut_tot_NA_	NA	NA	NA	NA	170
haut_tronc	0.5	2.2	2.9	16	NA
haut_tronc_NA_	NA	NA	NA	NA	1098
tronc_diam	3.0	90.0	95.6	395	NA
tronc_diam_NA_	NA	NA	NA	NA	191
age_estim	1.0	30.0	31.5	200	NA
age_estim_NA_	NA	NA	NA	NA	1020

La hauteur mediane est d'environ 8 m, le diametre median d'environ 89 cm, ce qui correspond a des arbres urbains d'age moyen (mediane de l'age estime a 30 ans).

2.1.2 Variables categorielles

La grande majorite des arbres est **en place** (91%), et 110 arbres sont classes comme remarquables. Les feuillus dominent largement (environ 86%). Les quartiers les plus peuples sont Saint-Martin - Oestres,

Remicourt et le Faubourg d'Isle.

2.2 Bivariees

Table 2: Moyennes des metriques par stade de developpement.

Stade	n	Hauteur moy.	Diametre moy.	Age moy.
adulte	6475	12.8	124.9	41.2
jeune	4620	6.7	52.2	13.3
vieux	68	23.5	198.6	63.1
senescent	53	22.7	204.7	98.9

Les moyennes augmentent logiquement du stade **jeune** vers **vieux**, ce qui confirme la coherence des variables mesurees (voir aussi la figure 4).

3 Nettoyage des donnees

3.1 Problemes identifies pendant l'exploration

L'exploration (script `01_exploration.R`) a mis en evidence :

- des modalites categorielles saisies de facon incoherente : "Jeune" vs "jeune", "Libre" vs "libre", "Bande de terre" vs "bande de terre"... ;
- la chaine **"RAS"** utilisee comme valeur manquante dans plusieurs champs (commentaires, noms) ;
- des **zeros suspects** : 158 haut_tot, 159 tronc_diam, 168 age_estim. Un arbre vivant n'a pas une hauteur ou un diametre nul ;
- une valeur `age_estim = 2010` (saisie d'une annee a la place de l'age) ;
- 2 arbres sans coordonnees geographiques ;
- 74 doublons sur (X, Y, nom latin) - pas des doublons d'identifiant mais probablement des arbres **replantes** au meme endroit ;
- des dates de plantation a **1970-01-01** (epoch Unix : valeur par defaut).

3.2 Regles appliquees

Les decisions ont ete prises en fonction des constats ci-dessus :

Regle	Justification
Modalites en minuscules sans accents	Uniformiser les doublons de casse
`"RAS"`, `""` → `NA`	Traiter les NA caches comme des vrais NA
`haut_tot`, `haut_tronc`, `tronc_diam`, `age_estim` a 0 → `NA`	Valeurs physiquement impossibles
`age_estim > 200` → `NA`	Annee saisie a la place de l'age
`tronc_diam > 400 cm` → `NA`	Invraisemblable (diametre > 4 m)
`haut_tronc > haut_tot` → `NA`	Incoherence physique
`dte_plantation == 1970-01-01` → `NA`	Valeur par defaut de la base

Regle	Justification
Lignes sans `X/Y` supprimees	Inutilisables pour la carte
Doublons (X, Y, nomlatin) gardes	Replantations legitimes

Apres nettoyage : **11419 lignes** (2 supprimees par rapport au brut). L'annee de reference pour `age_calc` est **2020** (annee maximale observee dans les donnees).

3.3 Gestion des valeurs manquantes restantes

Il reste des NA apres nettoyage. On a mesure dans quelle mesure une imputation par groupe aurait du sens, en calculant pour chaque variable numerique la part de variance expliquee par un groupe (R^2) :

Variable	Meilleur groupe	R^2	NA restants
`haut_tot`	nomlatin	0.50	170 (1.5%)
`tronc_diam`	fk_stadedev	0.44	191 (1.7%)
`age_estim`	fk_stadedev	0.51	1020 (8.9%)
`haut_tronc`	nomlatin	0.22	1098 (9.6%)

On a choisi de ne pas imputer :

- `age_estim` est la cible de la regression (Fonctionnalite 5). Imputer la cible biaise l'evaluation du modele.
- `haut_tot` et `tronc_diam` ont peu de NA (~1.5%) : l'impact d'une imputation est negligeable.
- `haut_tronc` a un R^2 trop faible (0.22) : la mediane par groupe serait arbitraire.
- `dte_plantation` a 86% de NA : la ville ne connait tout simplement pas la date pour une majorite des arbres. Rien ne permet de la reconstituer.

Les fonctions R gerent les NA nativement (`na.rm = TRUE`, retrait automatique dans `ggplot`). Le fichier exporte est `data/clean/arbres_clean.csv`.

4 Visualisations

4.1 Repartition par stade de developpement

La population est dominee par les adultes (~53%) et les jeunes (~40%). Les arbres vieux ou senescents restent marginaux, ce qui est coherent avec une gestion active du patrimoine (abattages, replantations).

4.2 Repartition geographique

Les quartiers Saint-Martin - Oestres, Remicourt et le Faubourg d'Isle concentrent la majorite des arbres. La distribution par secteur est tres longue : une poignee d'axes majeurs rassemblent beaucoup d'arbres, puis une longue traine de petits secteurs.

4.3 Distributions des metriques

Les deux distributions sont asymetriques a droite : beaucoup d'arbres petits ou moyens, quelques arbres tres gros. La hauteur totale se concentre entre 3 et 15 m, le diametre entre 30 et 150 cm.

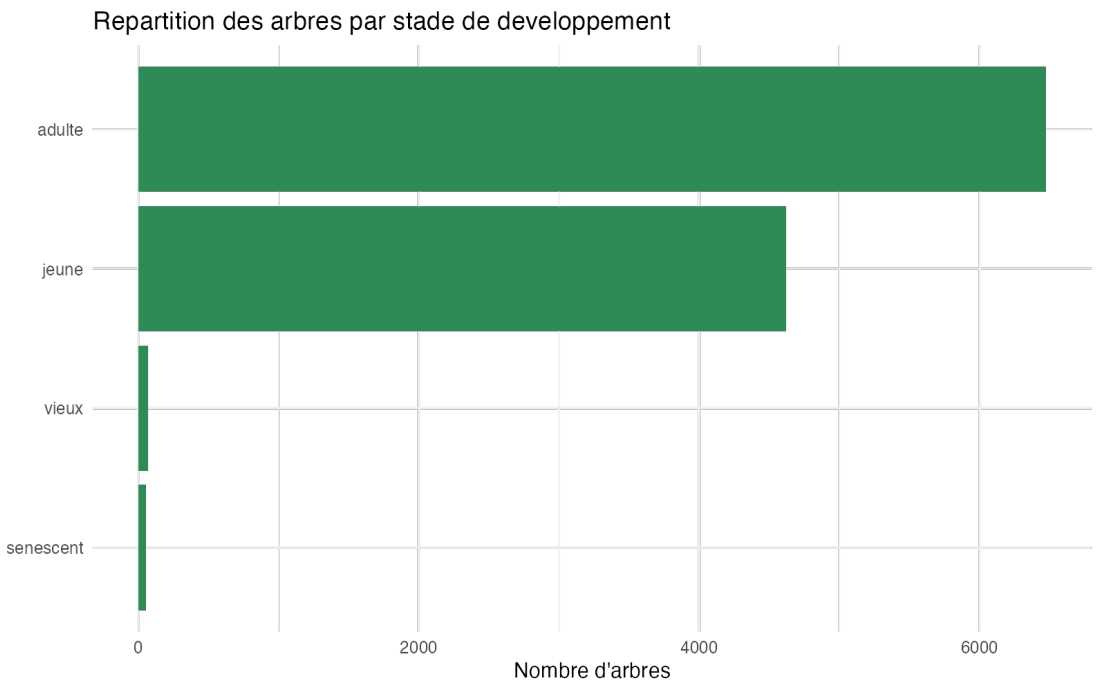

Figure 1: Repartition des arbres par stade de developpement.

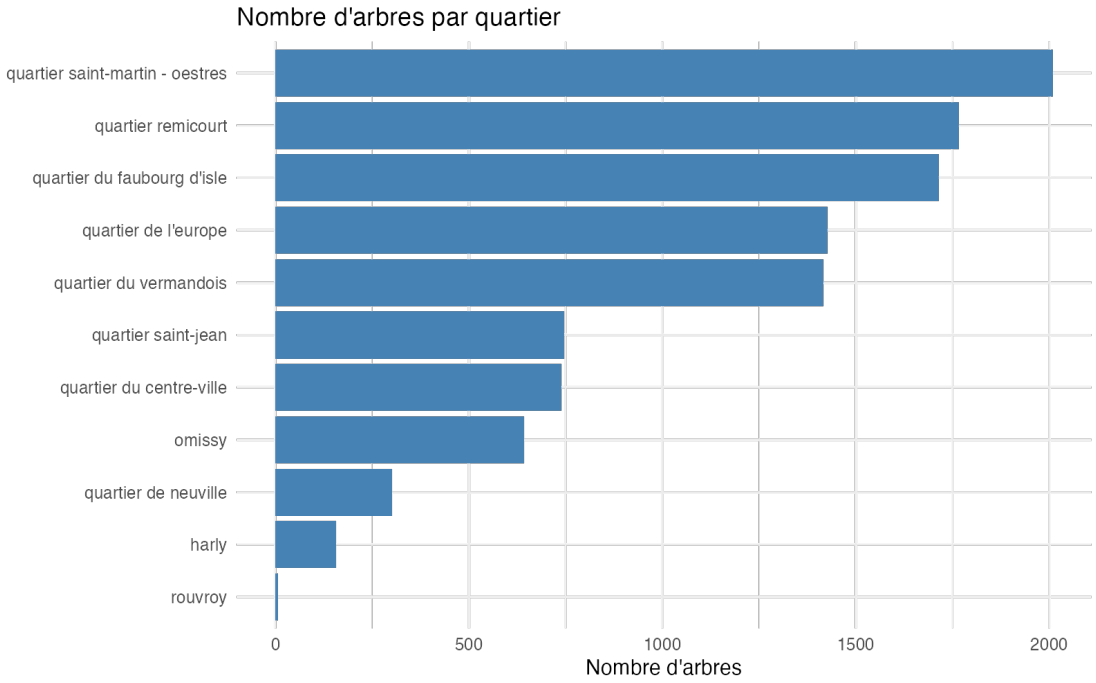

Figure 2: Nombre d'arbres par quartier.

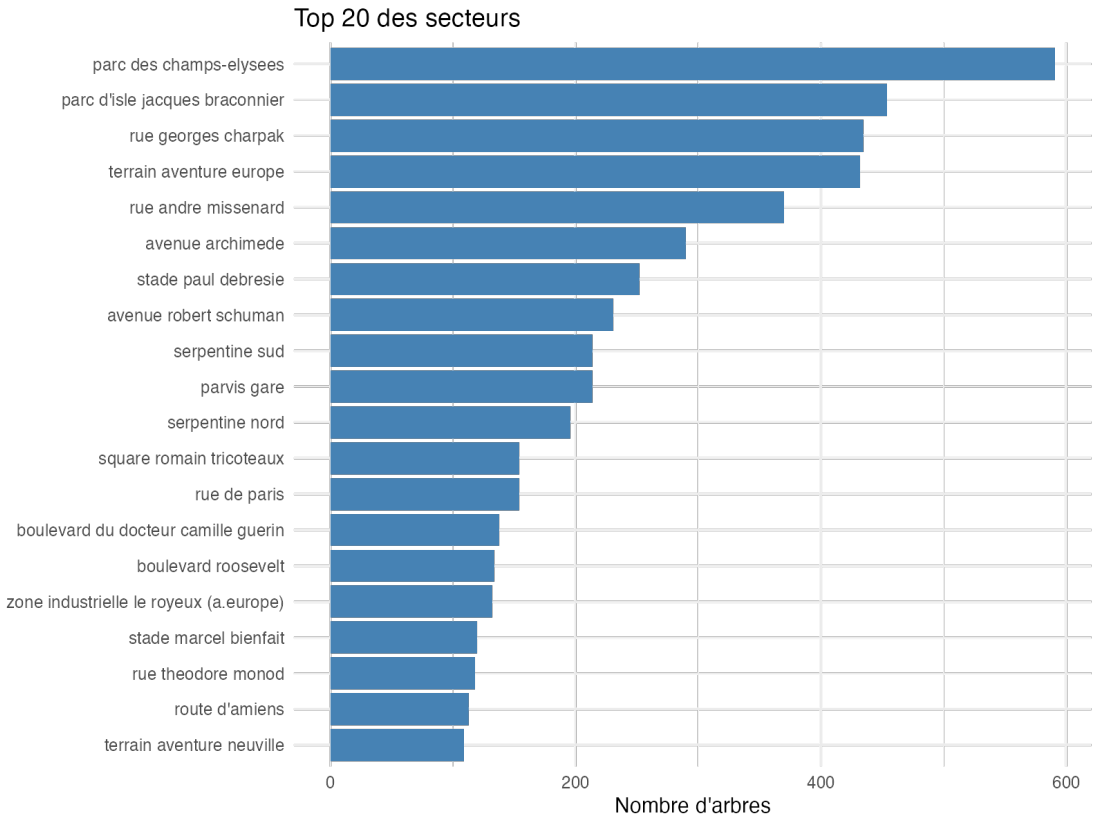

Figure 3: Top 20 des secteurs (rues / avenues).

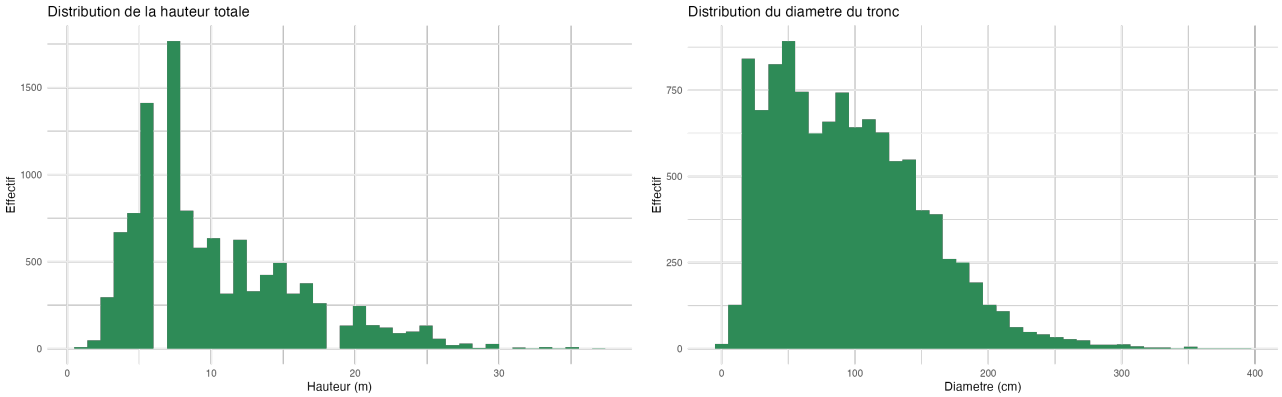

Figure 4: Distributions de la hauteur totale (gauche) et du diametre du tronc (droite).

4.4 Croisements

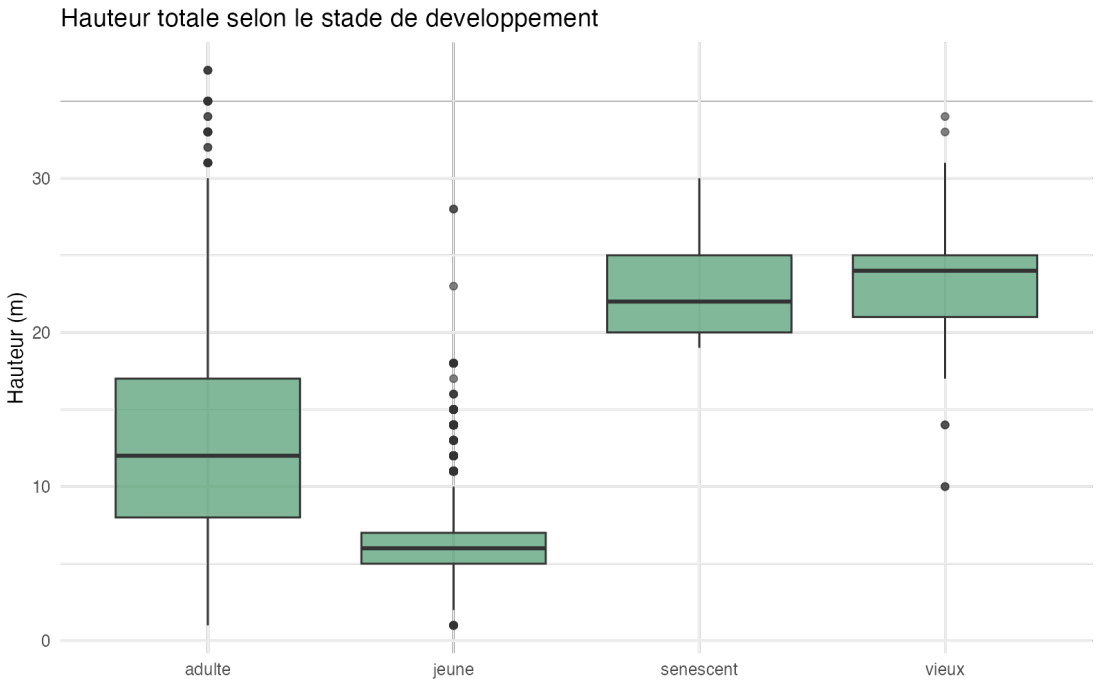

Figure 5: Hauteur totale selon le stade de developpement.

Les boites montrent une progression nette : jeune < adulte < vieux/senescent. La variance intra-groupe reste importante, ce qui explique que le R^2 par stade tourne autour de 0.3-0.5.

4.5 Especes

Le patrimoine est assez diversifie. On observe cependant la predominance de quelques especes classiques du paysage urbain francais (platanes, tilleuls, erables...).

4.6 Dynamique temporelle

La grande majorite des dates de plantation n'etant pas renseignee (86% de NA), ce graphique porte sur une minorite des arbres. Il reste utile pour visualiser l'effort de plantation des dernieres annees.

5 Conclusion

L'exploration a permis d'identifier des defauts typiques d'une base de saisie manuelle : incoherences de casse, NA codes en "RAS", zeros a la place de NA, quelques aberrations numeriques et une date par defaut epoch. Le nettoyage reste leger (seules 2 lignes supprimees) mais les regles appliquees rendent le jeu de donnees exploitable pour la suite du projet (carte, etude des correlations, regressions).

Le fichier `data/clean/arbres_clean.csv` sert de base aux Fonctionnalites 3 a 6.

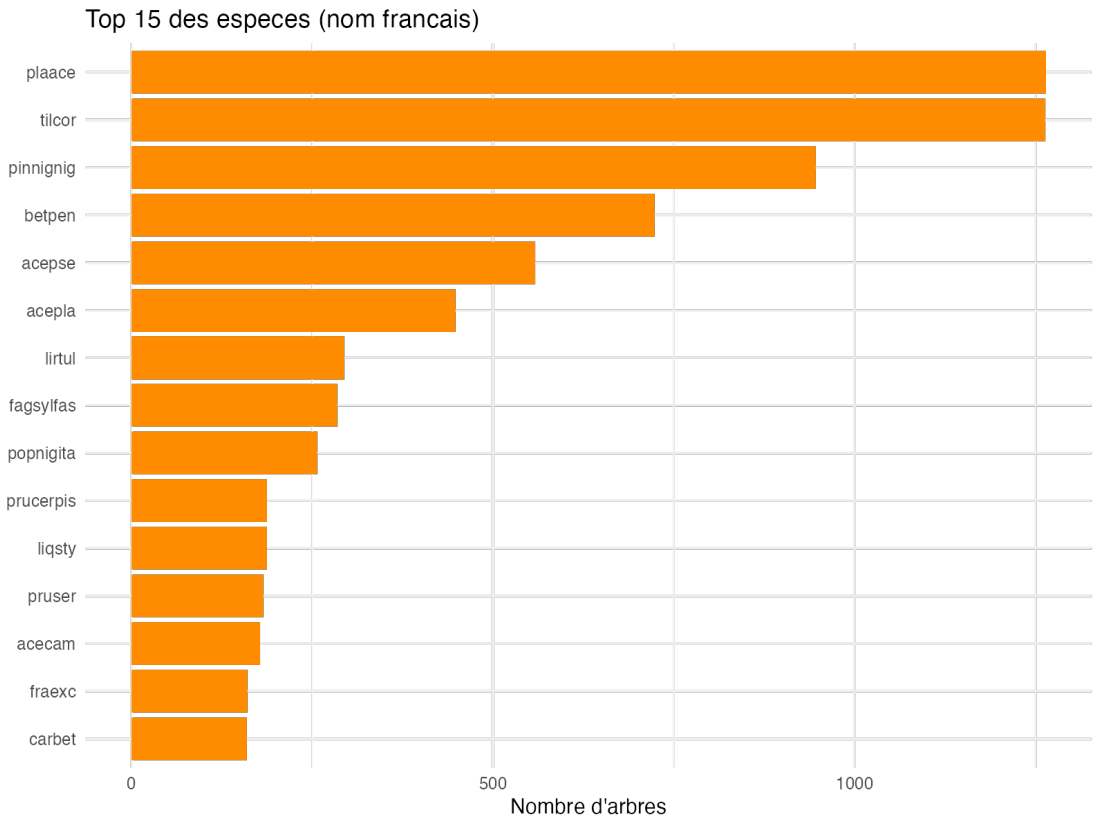

Figure 6: Top 15 des especes (nom francais).

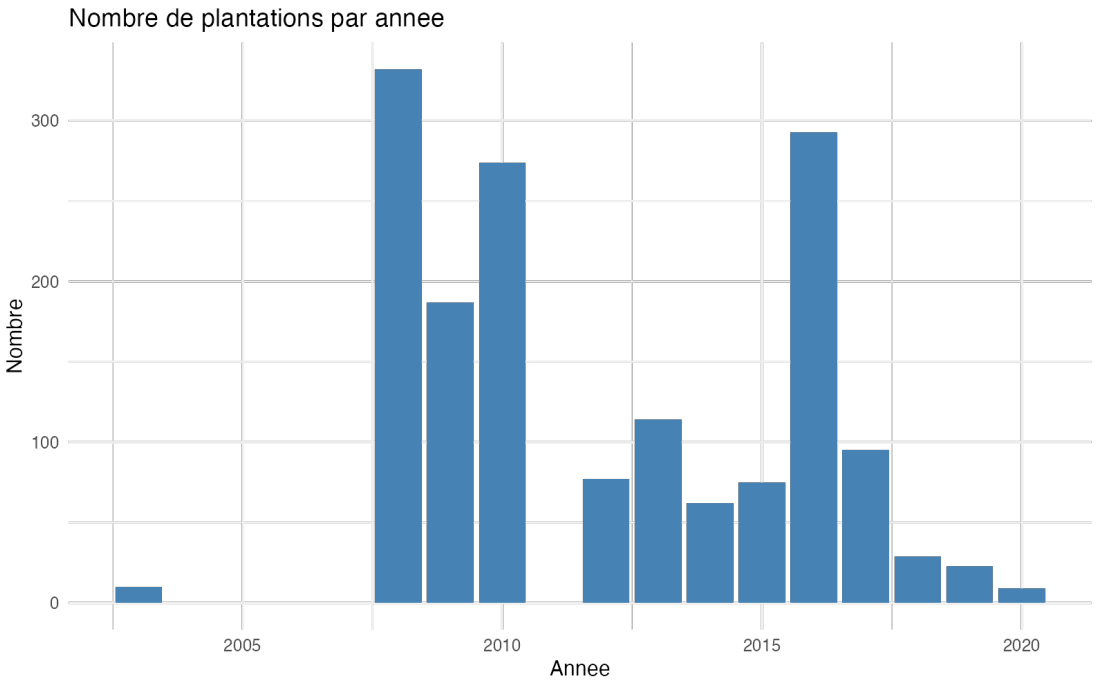

Figure 7: Nombre de plantations enregistrees par annee.